

ResNet-18 与 CIFAR-10 实践闭环验证报告

完整训练与两组单因素 ablation

Habit130

cv-research-practice 作者验证跑

作者终审草稿 · 2026-10-10

Abstract—本报告记录一个计算机视觉科研实践闭环的作者验证跑：从参考实现出发，建立运行前实验记录，在 Apple M5 / MPS 上完成 ResNet-18 与 CIFAR-10 的 baseline 及两组单因素 ablation，再将结果连接到报告。三组采用相同数据划分、随机种子与完整训练预算。固定最终 epoch 的 test accuracy 分别为 95.45%、95.11% 和 86.88%；关闭 shortcut 相加与固定学习率的差值分别为 -0.34 和 -8.57 percentage points。数字对应 EXP-05-07。实验条件下的结论已由作者批准；本文叙事与观点仍待作者终审。本报告不据单 seed 推断统计显著性，也不将参考实现自报数字当作严格匹配条件的对照。

I. 问题为什么重要：把结果连接到证据

科研初学者不仅需要跑通训练，还需要说清数据、模型、优化设置、运行条件和指标口径，才能判断一次对比究竟支持什么。本次验证跑的目标是检查本仓库使用文档中的实践闭环：论文选读、代码复现、实验记录、对比分析、报告写作。它是一个小型分类任务上的过程验证，不以产生新的模型方法或达到论文最优指标为目标。

本报告按理论指南的报告叙事与写作章节组织 [1]。论文阅读以残差网络工作为入口 [2]；该工作提出残差学习框架以缓解深层网络训练困难。本次把 shortcut 相加作为一个可操控因素，把 LR schedule 作为另一个因素。是否存在差异，交由同条件训练后的真实记录回答，而不是从模型名称预先断言。

II. 已有方法与证据缺口：参考数字的边界

采用公开参考实现 kuangliu/pytorch-cifar 的固定提交，随后在仓库外持久 fork 中保存实际 MPS runner 与 shortcut 开关 [4]。这些实现及 CIFAR-10 数据、权重不进入模板仓库。

早期完整训练在作者决定收窄范围后终止于 epoch 37，因此不能作为本次完整预算、固定 seed 的对照 [3]。作者随后批准恢复完整预算。新的 baseline 完成后，先核验结果并发布 Phase 2 后续说明，再放行两组 ablation；这一顺序及闸门历史记于 EXP-05。

参考实现自报 accuracy 为 93.02%。本次 baseline 的 best test accuracy 为 95.60% (epoch 189)，同口径诊断差距为 +2.58 percentage points[4]。上游自报表没有固定其 seed、设备和精确环境，因此该差距不能归因于某一修改；原始绝对差不超过 1pp 的数值门槛未满足。本次完成完整预算并明确了比较限制，不宣称严格复现验收通过。best 来自逐 epoch 观察同一 test 集，本次未保留对应权重；它只用于参考诊断，不能替代预登记的 final accuracy。

III. 做了什么：固定预算的单因素对照

A. 数据、模型与配置

使用 CIFAR-10 官方 50000 train / 10000 test 划分，不另拆 validation。归档与 train/test/meta 的 MD5 校验通过 [7]。训

练变换为带 padding 的随机裁剪、随机水平翻转、ToTensor 与 Normalize；评测使用 ToTensor 与相同 Normalize。准确率为 test 集正确分类比例，loss 为交叉熵。

三组均为随机初始化的 ResNet18，固定 seed=20261009，采用 SGD，初始 LR 0.1、momentum 0.9、weight decay 5×10^{-4} ，train/test batch size 为 128/100，训练 200 epoch，DataLoader workers 为 0[4], [5], [6]。Python、NumPy、torch 与 DataLoader generator 均固定种子；这不意味着 MPS 位级确定性。设备为 Apple M5 / MPS，内存 24 GiB；Python 3.11.15、PyTorch 2.12.1、torchvision 0.27.1、NumPy 2.4.4，macOS 27.2。三组启动前的 MPS 前向、反向与 eval 检查通过，没有 CPU 回退 [7]。

B. 对照因素与指标口径

baseline 采用 CosineAnnealingLR, $T_{\max} = 200$ ，每个 epoch 的训练、评测结束后调用 scheduler.step。EXP-06 只关闭所有 BasicBlock 的 shortcut 相加；投影分支参数保留但不参与计算。EXP-07 保留 shortcut，只取消 scheduler.step，将 LR 固定在 0.1[4], [5], [6]。

每组 ablation 单独与 baseline 比较；两个 ablation 之间同时存在结构与 schedule 差异，不能作单因素归因。主指标预先固定为 epoch 200 的 test accuracy，不按 best test accuracy 选权重。重新加载 no-shortcut 权重时必须依据 checkpoint variant 恢复 BasicBlock.use_shortcut=False，因为该开关不在 state_dict 中 [5]。

IV. 实验是否支持结论：观察与限制

A. shortcut 与 schedule 的条件化观察

在本次设备、数据划分、单 seed、SGD 与完整 cosine 预算下，只关闭 shortcut 相加，最终 test accuracy 从 95.45% 变为 95.11%，test loss 从 0.1730995893 变为 0.2076407678[4], [5]。最终 train accuracy 两组同为 99.998%；本次小幅 accuracy 差异不足以证明统计显著性，也不能外推到其他深度与任务。

在相同 baseline 条件下，只将 cosine 改为固定 LR 0.1，最终 test accuracy 从 95.45% 变为 86.88%，test loss 变为 0.3807913750[6]。这支持本次固定预算下该 LR 配置的最终表现较低，不支持“所有固定 LR 都更差”的判断。不同固定 LR、延长预算、多 seed 与 CUDA 尚未验证。

B. 成本与可追溯性

表I给出实际耗时。三组累计训练及评测为 55430.08841 秒，约 15.3972 小时 [6]。关闭 shortcut 保留注册参数但减少参与计算的分支；各组顺序运行且未控制温度和后台负载，因此耗时差不能作为结构或 schedule 的因果效率证据。

TABLE I
固定第 200 EPOCH 的真实结果。每个数值追溯至行末实验记录；耗时含训练和逐 EPOCH 评测，不含下载、PREFLIGHT、门禁等待及审查。

设置	Test accuracy (%)	差值 (pp)	Test loss	耗时 (h)	记录
baseline (cosine)	95.45	0	0.1730995893	5.2115	EXP-05
关闭 shortcut 相加	95.11	-0.34	0.2076407678	5.1725	EXP-06
固定 LR 0.1	86.88	-8.57	0.3807913750	5.0133	EXP-07

三组各有连续 epoch 1–200 的指标，loss/accuracy 有限，样本数正确；completed.json 与最终 checkpoint 的 epoch、variant、seed 和 metrics 一致 [4], [5], [6]。最终权重与指标文件 hash 记录在对应实验记录中，数据 MD5 与实际 runner/patch hash 也重新核对通过。CPU 仅用于加载 checkpoint 元数据，没有执行 CPU 模型评测。

V. 结语与作者终审范围

本次完成运行前登记、完整训练、单因素比较和数字到记录的连接。所支持的结论限于上述设备、划分、单 seed 与固定预算；它没有检验统计显著性、其他任务或跨设备稳健性。后续报告终审需要作者确认本文的问题定位、参

考差距解释与叙事是否忠实于实践目的。陌生人能否从冷启动照做使用文档，仍属于独立的后续验证任务，不能由本次作者验证跑替代。

REFERENCES

- [1] Habit130, 计算机视觉科研入门指南, 本仓库随附 PDF, §4.4–4.5, §6.4, §6.6, Table 7.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” CVPR, 2016. <https://arxiv.org/abs/1512.03385>.
- [3] EXP-04, Phase 2 提前终止记录及后续说明。
- [4] EXP-05, Phase 3 baseline: 配置、完整结果与参考差距。
- [5] EXP-06, Phase 3 no-shortcut: 单因素结果及加载约束。
- [6] EXP-07, Phase 3 constant-lr: 结果、对照表与累计耗时。
- [7] EXP-08, 数据完整性、MPS preflight 与环境。